金融时序预测中的文本：增量价值、进入方式与识别困难

检索截止：2026 年 10 月 28 日（北京时间）。本报告是有检索记录的范围综述与重点证据核读，不是已完成双人筛选、逐篇全文评估的系统综述，也不是元分析。配套目录保留 420 条按 DOI 与规范化题名去重的记录，分为 350 条“ 预测研究候选 ”和 70 条测量、机制、方法或综述；其中 2025 年 77 条、2026 年 87 条。年份统计采用题录保留的出版日期，可能与卷期年份不同。37 条有重点定位或核读笔记，其他记录不能据题名推断正面或负面结果。检索原始记录、程序、核验结果均留在同目录。

一、对你们两个问题的回答

文本可以有用，但“ 文本有信息 ”与“ 在强数值信息集之上有稳定、可实现的增量 ”是不同命题。现有论文已经认真研究这两个问题；最有启发性的研究往往把来源、时点、目标、基准与表示方式拆开，而不是把加入文本后的一个高准确率当作结论。

关于“ 有没有用 ”，可以找到历史新闻收益信号、披露变化、宏观新闻预测波动率等正面证据，也可以找到严格控制身份、时间、成本或多重检验后大幅缩水乃至不显著的结果。2026 年的新研究使这个问题更具体：文本模型可能只认出公司，可能只测量新闻到达，可能利用预训练的未来知识，也可能确实识别了数值尚未充分表达的当天语义。必须做实验区分。

关于“ 如何进入 ”，文献没有给出普适的最优融合架构。比较值得研究的是：文本的哪一部分是目标相关的、它相对于数值条件意味着什么、何时应该被忽略。任务监督的低维特征、结构化事件、文本预测与数值预测的组合、状态门控，以及模态专用编码与对齐，都有理由进入同一个公平比较。

这里的综合判断来自下文所列原始论文；不能把目录中的 420 条都视为赞成或反对某结论的投票。

二、先把“ 有用 ”写成可检验的问题

令 X_t 表示预测时点真实可用的价格、成交、波动率、基本面和其他数值信息，T_t 表示当时已完整可得的文本，Y_(t+h) 为未来目标。

若用平方损失预测条件均值，核心原假设是：

E[Y_(t+h) | X_t, T_t] = E[Y_(t+h) | X_t]。

若预测波动率分布、尾部风险或收益分布，则应检验对应条件分位数、条件方差或完整条件分布；文本可能不改变均值，却改变尾部或不确定性。预测目标不同，“ 无用 ”的含义也不同。

实际比较对象应是：在相同样本、可得信息时点、调参与算力预算下，X 模型与 X+T 模型的样本外损失差。这个差是“ 可估计的模型增益 ”，仍不完全等同于总体信息价值：有限样本、表示压缩和估计误差会让有信息的文本表现不好。

应区分五个层次：

证据	能说明什么	尚不能说明什么
情绪分类、QA 或事件抽取准确率高	语言任务完成得好	未来金融目标可预测
文本与当日价格反应相关	文本与已发生的市场信息有关	发布后仍有剩余预测价值
文本单独模型有效	T 含预测信息或代理变量	相对 X 有增量
X+T 样本外优于强 X 基准	在该任务和协议内有增量	跨时期、跨市场普遍有效
成本后仍改善风险调整效用	在指定执行假设下有经济价值	大资金容量、真实部署都可行

2026 年 QLoRA 基准直接展示了第一层与后几层的断裂：金融情绪分类改善，但其 28 个下游模型-预测期检验经过依赖和多重检验处理后没有保留显著性。原文，F017

三、文献已经深入到哪里

3.1 金融与经济学：从“语言测量”走向“条件增量”

Tetlock 的媒体情绪研究、Tetlock 等人的企业基本面语言研究，以及 Loughran-McDonald 的财务词典，分别推进了媒体语调、基本面信息和领域语义的测量。它们构成起点，但不能据此推断任意现代文本模型都有超额预测力。F036、F035、F034

Ke、Kelly 和 Xiu 的研究更直接回应“怎么进入”：词语筛选、权重和聚合针对收益目标训练，而不是先找一个通用“正面/负面”分数。这说明文本表征应该与金融目标一起设计；语言上的情绪正确，不保证收益目标上的排序正确。Predicting Returns With Text Data，F033

Lima 和 Godeiro 的结果尤其重要：把大量文本直接降维成因子，不能超过历史均值；先筛选具有预测性的词语，再估计因子并动态更新词典，才得到改善。这里题名中的 attention 是预测性关注与筛选，不能误读为证明 Transformer 注意力最优。Equity-premium prediction: Attention is all you need，F029；2022 在线、2023 卷期

Bybee 等人的新闻主题研究把关注度转换为经济状态和叙事，提供了有解释力的文本增强模型。不过文中关于市场波动的同期解释比例，不能改写为未来收益预测的 R^2。研究中递推的历史主题设定，比全样本主题更适合用来判断实时可预测性。Business News and Business Cycles，F027

披露变化是另一种进入方式。Cohen、Malloy 和 Nguyen 不只读一份报告有多乐观，而读同一企业相对上一份报告改了什么。文本差分可以过滤长期模板，聚焦新增或删除的信息。Lazy Prices，F031 制度外推需要小心：2026 年日本会议研究的摘要称，总体变化并不预测收益，新增增长词汇的方向才有信息。这是值得进一步核验的反例，而不是现成的跨国定律。Do Lazy Prices Hold in Japan?

3.2 波动率：新闻数量、来源与语义的贡献并不相同

Bodilsen 和 Lunde 发现，宏观新闻情绪对较长预测期的波动率有帮助，个股新闻情绪在一般设定下较弱，而隔夜个股新闻数量有助于短期预测。因此，不能把“新闻有效”自动解释为“深度语义理解有效”。Exploiting News Analytics for Volatility Forecasting， F028；2025 卷期

Rahimikia 和 Poon 的 2026 年研究在较强 HAR 家族基准下比较新闻和订单簿信息，报告新闻数量的增益比情绪更稳定，而且在高波动日更明显。它给你们一个很必要的对照：如果只加新闻篇数就获得全部改善，复杂语言模型并未证明有额外语义价值。Alternative Data for Realised Volatility Forecasting， F002

Fernandes 和 Pereira 用巴西新闻构建不确定性指标，在持久性、杠杆效应、跳跃和微观结构等控制之后仍报告预测改善，较长预测期尤其明显。这提示文本新闻周期的持续性可能与波动率预测期匹配。Forecasting realized volatility using news flow， F026

FinText 研究的最新版更加审慎：新闻单独模型通常无法超过最强波动率历史基准；但把新闻预测与强基准结合，可以降低部分设定中的损失并改善实现效用。采用的是 2026-08-31 的 v7，不能沿用更早版本的强表述而忽略修订。Realised Volatility Forecasting: Machine Learning via Financial Word Embedding， F030

以上研究为“文本补充数值模型”提供了证据，但波动率不应因此被断言为普遍比收益更容易从文本获益。本次没有做跨任务可比的元分析。

3.3 机器学习与 NLP：融合设计很多，识别质量需要逐篇判断

StockNet 是文本与历史价格联合建模的代表性早期工作；后续模型大量探索新闻层级注意力、关系图、跨模态注意力以及电话会文本-音频融合。Stock Movement Prediction from Tweets and Historical Prices， F347、VolTAGE， F305

这类架构论文回答的是特定数据和比较集上的方法问题。读论文时，应确认纯数值基准是否足够强、是否与联合模型等预算、是否使用相同测试样本；还应区分“去掉文本后模型变差”和“已经证明文本具有独立语义贡献”。如果去掉文本同时移除了公司身份、新闻数量或额外模型容量，消融仍有歧义。

2025 年 Guo 和 Hauptmann 直接比较不同复杂度的融合，发现简单的表示组合通常优于更复杂方法，融合效果依投资股票池而变，解耦训练的混合预测更稳健。微调语言模型的影响也不一致。作者把部分差异解释为市场效率与数据差异，但这不是单独识别出的市场效率因果效应。Exploring the Synergy …， F021

Koval、Andrews 和 Yan 的 2025 年研究则提供另一条正面路线：保留文本与时序交错的结构，给两种模态不同专家，并对齐重要 token。它认真比较单模态与多模态基准；其优势支持这套设计在该实验内有效，不能据此宣称所有任务都应端到端使用语言模型。预印本与 IJCNLP 正式版本在目录中合并为一项研究。F020

四、2025-2026 年出现的关键困难与发现

4.1 最直接的近期证据：高独立预测力可能主要是公司身份

Zheng 的 2026-10-18 论文对 202,145 个被讨论股票日进行滚动测试。文本独立模型的拟合并不代表当天新闻增量；公司身份控制、公司内部文本日期置换和 ticker 遮蔽把两者拆开。作者报告 HAR 加文本后等日期 MSE 改善 1.22%，但后期子样本并无显著正增量。More Mentions, Less Information?， F004

对你们的启发是把“当天语义”与稳定身份分开，分别检验新闻数量、文本有无和日内配对。该研究仍是回溯评估，不能被描述为已经消除了所有预训练污染。

4.2 正的策略收益未必代表文本增量

Foley 等人在 2026-10-15 的 NoLBERT 研究中使用早于预测样本的语言预训练，重新检查主题与收益。验证集选出的最佳实验在测试期失败；价格与文本组合的月度净 Sharpe 为 1.12，却没有显著超过价格组合。多重实验调整进一步削弱证据。Reading the News Without Hindsight， F012

这篇最适合作为研究设计范本，而不是“文本无用”的最终裁决：需要同时报告对零收益的检验、对数值基准的检验和搜索调整，三者检验的对象不同。

4.3 预训练污染真实存在，但大小依模型和任务而变

Levy 的 2026 年 JAR 论文提示，部分金融 AI 的强表现来自数值推理缺陷被掩盖、训练年代与被预测事件重叠等问题。Caution Ahead， F003

另一边，He 等人的 ChronoBERT/ChronoGPT 按历史文本截止训练，相关资产定价应用仍表现有竞争力，其估计的前视偏差较温和。两组发现共同要求逐模型、逐目标诊断，而不是把所有文本结果归因为记忆。Chronologically Consistent Large Language Models， F025

Gao、Jiang 和 Yan 提出 LAP 检验，以日期记忆诊断预测是否被未来知识放大。采用 2026-06-12 v2，标题已更新为 Detecting Lookahead Bias in LLM Forecasts。F022

污染诊断也可能失灵。MemGuard-Alpha 的修订稿显示，部分高检测 AUC 来自模型尺度或由时间直接定义的标签，统一处理成本后过滤并没有提升组合绩效。不能以一个漂亮的污染检测分数宣称回测已“净化”。F014

4.4 训练-测试按时间切开，也可能仍在事件内部偷看未来

2026-10-15 的 Availability Contract 研究指出：完整电话会转录包含问答后的信息，目标收益却可能从电话会开始甚至之前计算。移动目标开始时点会改变标签和预测损失。因此，必须说明完整输入何时可得，再加处理延迟，最后才开始计算目标。When Does“Post-Call”Begin?， F016

实施上应把五个时钟写入数据协议：事件发生、首次发布、修订、完整输入可用、模型生成与交易。 如果模型只能在盘后拿到完整文本，就不能把盘中已经完成的价格反应写成其可交易收益。

4.5 更多文本、更长上下文、更大模型并不自动更好

2026-10-16 的 SEC 披露评估发现：给同一披露加入基本面横截面排序能改善收益排序；给分析师摘要没有类似平均改善。金融专用模型的优势也不稳定。其任务还混有事件当期反应，不能全当作纯粹前瞻预测。From SEC Filings to Financial Signals， F015

2026-10-22 的新闻老化研究比较“保留旧新闻并告知年龄”与“先过滤旧新闻”，RL 对时间信息的行为反应并没有变成稳定历史收益改善。它支持研究信息选择，而不只是增加上下文长度。When News Gets Old， F011

4.6 单一情绪会丢信息，但结构化新结果也须过时间检验

2025-12 的 SER 工作以结构化事件进入预测器；2026-07 的 Beyond Sentiment 把事件类型、主体、时间范围和置信等语义与情绪结合。这些设计比单一极性更接近金融问题。F024、F008

但 F008 的全文方法是：对全体样本 bootstrap 后再随机划分 80%/20%。这既未隔离未来时期，还可能使同一原始观测的重复副本跨越训练和测试。因此它的 F1 改善只能作为有待严格复验的线索，不能当作实时增量已经成立的强证据。

4.7 数值背景可能改变同一句文本的方向

“ 利润增长 ” 不一定是利好，关键可能是低于市场预期；“ 成本下降 ” 也可能来自需求崩塌。模型应解释文本相对于预期、估值、波动率状态和资产暴露的意义。这是从 F015 条件信息比较中得到的研究启发，而不是该论文已证明了所有交互机制。

2026-10-15 的合成公告实验进一步说明输入冲突值得测：多数被测模型对无新增信息的语调或动量比对 EPS 意外更敏感。但合成实验测的是输入依赖，不能据此推出真实投资回报。Momentum, Commentary Tone, and Earnings Surprise ⋯， F013

4.8 最新基准本身也必须审查

2026-10-12 的 XForecast 将新闻和价格配对，预测四周后的股票方向。但其加权命中率利用实现后的价格方向衡量新闻的重要性。因此 “ 在该指标上胜出 ” 不能直接等同于无偏的事前信息价值；应同时报告未加权指标和对强数值基准的增量。XForecast， F005

2026-09 的 MM-FinEval 扩展到电话会文本、音频和幻灯片，适合研究模态互补。仍须查看语言模型训练截止、电话会完成时点，以及标签究竟是当期解释还是未来预测。F007

检索还覆盖到 2026-10-26 的 FinLLM-KG：历史 10-K 公司知识以资料或三元组形式进入推理，作者报告组合改善。这是 “ 相同新闻应按公司背景解释 ” 的最新例子，但目前在本报告中只作为摘要核读的新预印本，不作为已复现结论。F018

五、文本究竟应该如何进入：把表示与融合分开比较

5.1 表示层：至少比较以下六类

表示	保留什么	容易丢掉什么	适合检验的问题
篇数、是否有新闻、来源、时间、新颖度	到达强度、覆盖与时钟	具体语义	改善是否仅来自信息到达？
金融词典、情绪、分歧	方向、语调、意见差异	主体、条件、预期与事件结构	是否简单低维信号已足够？
主题或叙事状态	宏观风险、行业和经济主题	细粒度事件与预期偏差	跨期风险和状态是否可预测？
稀疏监督词语与低维投影	与特定目标相关的词和方向	未经保留的含义	目标监督是否比通用表示重要？
冻结嵌入及其压缩	较丰富上下文与语义近邻	明确经济约束、身份与语义分离	是否确有不可由数值代理的语义？
结构化事件与历史差分	谁、什么、何时、意外程度、暴露、修订	抽取错误、难以枚举的叙事	收益是否来自事件与预期匹配？

可优先把结构化事件写成“ 主体-事件-对象-预期差-时间范围-影响渠道-可信度 ”，但这些字段是建议的实验设计，不意味着现有文献已共同验证了这一最佳集合。新闻中披露的数字也应单独抽取：这样可以区分模型只是把文字中的 EPS 数字搬进来，还是语言语义真的增加信息。

5.2 融合层：从最容易解释的组合开始

进入方式	形式示意	价值	主要风险
特征增广	预测器接收 [X, z(T)]	控制清楚、易与数值基准比较	高维小样本、文本支路过拟合
预测组合	w*f(X)+(1-w)*g(T)	可分离两种预测器，冻结表示也可用	权重若用测试期选择会泄漏
残差修正	f(X)+g(T,X)	直接针对数值基准遗漏部分	训练残差必须用时间外预测产生
状态门控	f(X)+a(X,T)*g(X,T)	可在噪声、缺失或旧新闻时回到基准	门控塌缩、模态捷径、训练不稳定
跨模态注意力或对齐	数值状态查询相关文本	允许上下文条件化、事件选择	注意力权重不是因果贡献
交错序列与模态专家	按真实时间交错文本和价格片段	保留事件顺序与反应过程	时钟、模型年代和算力要求更高

这些路线应放进同一数据协议比较。F021 支持不要预设复杂注意力必胜；F020 支持在交错时间关系重要时认真测试专用专家。F023 的 M2VN 在历史时点嵌入下加入对齐损失并做去新闻消融，说明“ 对齐 ”和“ 污

染控制 ” 可以一起研究。F021、F020、F023

需特别区分：把数字转成字符串后交给 LLM 的论文，并不天然研究外部文本是否有用；RAG 检索历史数值片段的收益，也不能全部归为新闻语义贡献。例如 FinSrag 的核心改进是金融时序检索，应放在方法支撑而非新闻增量的直接证据中。F149

六、一个真正回答你们问题的实验矩阵

6.1 固定信息边界与样本

选定资产和预测时点，例如美国股票收盘前可用信息、或中国股票开盘前已发布公告。建立真正的历史股票池，保留退市样本。数值基准和文本模型使用同一测试股票日；全样本结果与 “ 有新闻日 ” 结果分别报告。文本缺失可能有信息，不能把缺失日悄悄删除再与不同样本的数值基准比较。

滚动或扩展窗口划分训练、验证与测试。重叠标签要依据预测跨度留出间隔；所有标准化、PCA、词典筛选、主题估计、特征选择、提示选择及模型选择只能使用当时的训练/验证信息。语言模型的预训练、后训练、检索资料与工具访问都有自己的截止日期。

6.2 建议的分组对照

组别	输入	它排除的替代解释
B0	强数值 X	建立公平起点
B1	X + 公司/行业/规模等稳定控制	文本只是识别公司
B2	X + 新闻有无、篇数、来源与时间	文本只是信息到达或覆盖
B3	X + 文本中的结构化数字	文本只是传递数字
B4	X + 情绪/主题	低维语义已足够
B5	X + 历史一致冻结嵌入	丰富表示是否还有增量
B6	X + 结构化事件/预期差/文本变化	哪种语义成分有用
B7	B5/B6 + 条件化或门控	增益是否依状态与匹配
P1	公司内部、局部时间块的文本配对置换	预测是否依赖当天对齐
P2	遮蔽名称与日期、仅保留身份、删除语义	身份和记忆通道
P3	不增加新事实的语气改写与符号冲突	模型是否被表达方式带偏
P4	人为延迟、删除重复新闻、只保留首次报道	到达时间与新颖度

置换不能随意破坏金融数据依赖结构，应保留公司和局部状态，且把检验对象写清楚。删名称也不是保证无污染，因为业务事实本身可能识别公司。

6.3 基准与损失

收益任务：历史均值、合理的线性/正则化因子模型、树模型等数值基准；按具体市场加入适用的基本面与技术信息。报告样本外 R^2、RankIC、校准、成本后组合回报以及相对数值策略的效用差，避免只预测高度持久的价格水平。

波动率任务：HAR 家族、杠杆/半方差/跳跃/测量误差等合理增强，以及树或其他非线性数值模型；数据允许时加入隐含波动率。不能只用最弱 HAR 比较。报告 MSE 与 QLIKE，并分普通日、高波动日、跳跃日以及不同预测期。对非负预测、log 变换回转与 Jensen 偏差作一致处理。

若 v 为实际方差、h 为方差预测，可用 QLIKE(v,h)=v/h-log(v/h)-1（正值定义域）；所有模型必须预测同一种对象，不能混用波动率与方差。

方向任务：与多数类、简单方向规则和适合的不平衡分类基准比较；用 MCC、平衡准确率、AUROC 等补充准确率，并说明被丢弃的“ 平盘 ”样本和标签阈值。不同论文的准确率无法脱离标签构造直接排序。

统计推断须处理时间依赖、同一天横截面相关和重叠目标。DM、嵌套模型检验、块 bootstrap、多重检验或模型置信集应与具体比较相匹配，不是把所有检验机械叠加。跨股票的成千上万行不等于独立的成千上万个交易日。

6.4 从平均增量进一步问“ 哪里有用 ”

在预先设定的状态上比较损失差：低/高波动、突发/例行事件、公司/行业/宏观新闻、首次/重复报道、大/小市值、低/高分析师覆盖、不同来源及预测期。

不要只报告表现最好的子组。要把选择过程计入推断，给出整体结果、各子组置信区间和跨阶段稳定性。若文本仅在极少数突发日有帮助，平均误差可能掩盖价值；但极端日改善也可能被少数事件驱动，需要事件留出检查。

七、值得你们优先发展的选题

选题 A：文本增量的来源分解

问题：数值之上剩余的预测价值，究竟来自身份、报道数量、文字中的数字、语义事件，还是与当天价格状态的匹配？

做法：实施 B0-B7 与局部置换负对照，分别预测收益、波动率或尾部。论文贡献可以是一个清楚的增量分解，即使最终发现大模型语义只贡献很小部分，也有研究价值。F004 与 F002 提供直接切入口，但更广资产与历史一致模型仍需检验。

选题 B：文本的条件价值，而非一个固定权重

问题：为什么相同利好语调在不同估值、预期与波动率状态下反而产生不同作用？

做法：构建预期差和事件暴露，比较简单拼接、预测组合、残差修正、门控和条件注意力；让模型允许忽略文本。重点是能被负对照推翻的条件机制，而非增加几个模块后只报平均准确率。F015、F021 和 F023 是合适的起点。

选题 C：语义新颖度、发布时间与预测半衰期

问题：文本的新信息相对哪个过去窗口定义？延迟多久后价值消失？短期收益信号消失后是否仍有风险信号？

做法：首次报道与修订分开，人工延迟 5 分钟、半小时、一天等，并按市场可交易性确定合理间隔。比较固定衰减、学习衰减和直接过滤。F011、F012 和 F016 把衰减、参考窗口与时钟边界联系起来。具体延迟网格应按数据频率设计，不能照搬。

选题 D：无前视条件下的融合边界

问题：历史一致模型、现代通用模型与金融专用模型的真实差距有多大？复杂融合的增益是否只存在于污染或小样本条件？

做法：冻结不同历史年份的模型，统一下游预测器、预算和资料快照，再比较表示、融合与微调。F025、F022、F003 和 F023 提供方法与相反证据。模型训练截止可验证性是这个项目的重要资源约束。

本次检索已经发现这些方向的近邻研究，因此不应声称“首次研究文本有无价值”。更可靠的贡献定位是：在具体市场、目标、时钟与强基准下，把既有文献尚未一起分离的通道进行受控比较。正式立项前应对最接近的 10-20 篇全文和代码继续做差异核查。

八、建议的首轮阅读顺序

1. F004：识别公司身份、对齐与真实增量，最贴近你们的原始问题。
2. F002、F028、F030：新闻数量、语义与强波动率基准，理解“补充”的边界。
3. F012、F017：正收益、语言分类成功与文本增量的断裂。
4. F021：简单融合、混合模型与微调为什么不总有效。
5. F020、F023：两条认真处理融合与模态差异的正面技术路线。
6. F025、F022、F003、F016：预训练记忆与事件内部时钟两类不同泄漏。
7. F033、F029、F031、F027：任务监督、词语选择、文本变化与经济叙事。
8. F015、F019、F011、F018：2026 年 10 月的条件信息、选择、新闻老化与公司背景。

九、检索口径和本报告的局限

本次使用 Crossref、OpenAlex 和 arXiv 的 API，以 45 组跨主题检索式为主体，辅以经典题名/DOI 查询、arXiv 专题检索和 2026 年 10 月补检。使用期刊、ACL Anthology、arXiv、SSRN 和作者机构页面核对关键内容。批量检索记录数、失败请求、去重与最终纳入数见“检索与核验说明.md”及 JSON 日志。

纳入范围以金融资产收益、价格方向、波动率、风险预测为主，辅以宏观、汇率、商品和必要的金融 NLP 测量方法。风险分类、破产、情绪测量和宏观预期文献是邻接证据，不能冒充同一项金融时序预测任务。中文及非英语研究有纳入，但未系统覆盖 CNKI、万方、付费 Web of Science、Scopus 或所有 SSRN 工作论文，英文数据库覆盖偏差仍然存在。

目录多数记录只完成题名和元数据筛选；有摘要字段并不表示本次已逐篇读完摘要。未完整获取的研究不填写样本量、增益或消融结论，也不将“未核读”写成“作者没有做”。重点核读没有独立复现代码，不能给论文盖上已复现的质量认证。

原始题录可能把早期工作论文年份与后续出版 DOI 混合，或保留改题版本。最终核验保留未解决条目的状态；正式投稿时还需按采用版本核对卷期、页码、作者顺序与可得日期。新预印本的存在和摘要可核实，不等于结果已经经受评审或复现。

为了避免错误的“共识”，本报告不计算 420 条中的正面结果比例，不计算不可比指标的平均提升，不把同一期刊名、注意力权重或显著性本身当作因果识别，也不声称某个方向无人研究。